

Раздел 3. Базы данных

Содержание:

1. Реляционная модель данных: Основные понятия: отношение, атрибут, кортеж, домен, схема, степень. Ключи: потенциальный, первичный, внешний.
2. Основы SQL. SELECT: синтаксис, порядок выполнения. Фильтрация, сортировка, агрегация. Соединений (JOIN), типы соединений. Теоретико-множественные операции.
3. Оконные функции в SQL: синтаксис OVER(), PARTITION BY, ORDER BY. агрегатные функции в оконном контексте. Ранжирующие функции. Смещения. Фреймы.
4. CTE (Common Table Expressions): Синтаксис WITH, рекурсивные CTE.
5. Проектирование баз данных. Обеспечение целостности, устранение аномалий, минимизация избыточности. Этапы проектирования: Концептуальное (ER-диаграммы, связи), логическое (нормализация), физическое.
6. Нормализация в базах данных. Нормальные формы: определения 1НФ, 2НФ, 3НФ, НФ Бойса-Кодда.
7. Транзакции в SQL. Команды для работы с транзакциями. Свойства ACID: Атомарность, Согласованность, Изолированность, Долговечность.
8. Уровни изоляции транзакций. Проблемы изолированности: "Грязное чтение", "Неповторяющееся чтение", "Фантомы".
9. План запроса: Операторы EXPLAIN и ANALYZE. Чтение и анализ плана (Seq Scan, Index Scan, Join методы).
10. Индексы: Назначение, условия использования. Типы: B-Tree, Hash, GiST, GIN, BRIN (номинально)
11. Методы доступа к данным: Seq Scan, Index Scan, Index Only Scan, Bitmap Scan.
12. Буферный кэш и WAL (Write-Ahead Log): Принципы работы, роль в обеспечении ACID.
13. Реализация изоляций транзакций в PostgreSQL. Версии строк. Снимки данных. Отмена транзакций. Горизонт транзакции и горизонт базы данных. Ручная и автоматическая очистка (VACUUM).

Введение (Главные определения раздела):

def База данных (БД) – это:

- совокупность данных, хранимых в соответствии со схемой данных, манипулирование которыми выполняют в соответствии правилами средств моделирования данных.
- Некоторый набор перманентных (постоянно хранимых) данных, используемых прикладными программными системами какого-либо предприятия.

def Система Управления БД (СУБД) – это совокупность программных и лингвистических средств, обеспечивающих управление созданием и использованием БД.

1. Реляционная модель данных: Основные понятия: отношение, атрибут, кортеж, домен, схема, степень. Ключи: потенциальный, первичный, внешний.

def Модель данных – это

- Абстрактное, самодостаточное, логическое определение объектов, операторов и прочих элементов, в совокупности составляющих абстрактную машину доступа к данным, с которой взаимодействует пользователь.
- Инструмент, формальная теория представления и обработки данных в СУБД, включающая по меньшей мере три аспекта:
 - Аспект структуры: методы описания типов и логических структур данных в БД;
 - Аспект манипуляции: методы манипулирования данными;
 - Аспект целостности: методы описания и поддержки целостности БД.

Реляционная модель данных

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
0	-122.23	37.88	41.0	880.0	129.0	322.0	126.0	8.3252	452600.0	NEAR BAY
1	-122.22	37.86	21.0	7099.0	1106.0	2401.0	1138.0	8.3014	358500.0	NEAR BAY
2	-122.24	37.85	52.0	1467.0	190.0	496.0	177.0	7.2574	352100.0	NEAR BAY
3	-122.25	37.85	52.0	1274.0	235.0	558.0	219.0	5.6431	341300.0	NEAR BAY
4	-122.25	37.85	52.0	1627.0	280.0	565.0	259.0	3.8462	342200.0	NEAR BAY
...	...	...	...	...	...	...	...	...	...	...
20635	-121.09	39.48	25.0	1665.0	374.0	845.0	330.0	1.5603	78100.0	INLAND
20636	-121.21	39.49	18.0	697.0	150.0	356.0	114.0	2.5568	77100.0	INLAND
20637	-121.22	39.43	17.0	2254.0	485.0	1007.0	433.0	1.7000	92300.0	INLAND
20638	-121.32	39.43	18.0	1860.0	409.0	741.0	349.0	1.8672	84700.0	INLAND
20639	-121.24	39.37	16.0	2785.0	616.0	1387.0	530.0	2.3886	89400.0	INLAND

20640 rows × 10 columns

def Отношение – математическая структура, которая формально определяет свойства различных объектов и их взаимосвязи. (Проще: табличка с данными, в которой не определен порядок строк и столбцов, а также нет двух одинаковых строк)

def Реляционная алгебра – коллекция операций, которые принимают отношения в качестве операндов и возвращают отношение в качестве результата. (Проще: набор

функций, принимающих на вход и возвращающих табличку (отношение))

def Домен – это множество допустимых значений.

def Атрибут – наименование домена. *(Проще: название колонки)*

def Кортеж – упорядоченный набор фиксированной длины. *(Проще: строка таблицы)*

def Арность отношения (степень) – количество атрибутов отношения.

def Заголовок отношения – список атрибутов.

def Тело отношения – множество кортежей в составе отношения.

Ключи

def Потенциальный ключ (Candidate key, СК) – это подмножество атрибутов отношения, удовлетворяющее требованиям уникальности и минимальности:

- Уникальность: нет и не может быть двух кортежей данного отношения, в которых значения этого подмножества атрибутов совпадают.
- Минимальность: в составе потенциального ключа отсутствует меньшее подмножество атрибутов, удовлетворяющее условию уникальности. (Не можем из имеющегося потенциального ключа вычеркнуть атрибут и вновь получить потенциальный ключ)

def Первичный ключ (Primary key, РК) – это один из потенциальных ключей отношения, выбранный в качестве основного.

- Если в отношении имеется лишь один СК, он и будет первичным ключом. В противном случае один ключ выбирается в качестве первичного, а остальные называются альтернативными.
- Отсутствие значения для РК недопустимо.
- В теории, все потенциальные ключи одинаково пригодны для использования в качестве РК, но на практике используется СК, занимающий меньше места при хранении и который не утратит свою уникальность со временем.

def Суррогатный ключ – это дополнительное служебное поле, которое добавляется к уже имеющимся информационным полям таблицы только чтобы служить первичным ключом.

- Значение генерируется искусственно и смысловой нагрузки значение не несёт.
- Обычно является числовым полем и генерируется за счет автоинкремента. (Для PostgreSQL это реализовано в типе данных `SERIAL`)

Достоинства суррогатных ключей	Недостатки суррогатных ключей
<i>Неизменность</i> : заполнили одним значением раз и навсегда (кроме экстраординарных ситуаций).	<i>Уязвимость генераторов</i> : по номерам ключей возможно узнать число новых записей за определенный период времени.
<i>Гарантированная уникальность</i> : т.к. значение генерируется автоинкрементом, повторение значений исключено.	<i>Неинформативность</i> : усложняется ручная проверка БД.
<i>Гибкость</i> : т.к. такой ключ не несет никакой информативной нагрузки, его можно свободно заменить.	<i>Склоняет к пропуску нормализации</i> : декомпозиции предпочитают создание суррогатного ключа.
<i>Эффективность</i> : удобнее при создании ссылок на другие таблицы.	<i>Привязка разработчика к поведению генератора ключей в конкретной СУБД</i> .

def Пусть R_1 и R_2 – две переменные отношения, необязательно различные. **Внешним ключом (Foreign Key, FK)** в R_2 является подмножество атрибутов переменной R_1 такое, что выполняются следующие требования:

- В переменной отношения R_1 имеется потенциальный ключ РК такой, что РК и FK совпадают с точностью до переименования атрибутов.
- В любой момент времени множество всех значений FK в R_2 является подмножеством значений РК в R_1 .

то есть:


- R_1 содержит потенциальный ключ и является главным, целевым или родительским отношением.
- R_2 содержит внешний ключ (Foreign Key, FK) и называется подчиненным или дочерним отношением.

родительское отношение

author_id (PK)	author_name
1111	Джордж Оруэлл
1024	Олдос Хаксли
8800	Эрих Мария Ремарк

дочернее отношение

id (PK)	book_name	author_id (FK)
924	1984	1111
822	Гений и богиня	1024
215	О дивный новый мир	1024
535	Триумфальная арка	8800
353	Ночь в Лиссабоне	8800



def Ссылочная целостность – это необходимое качество реляционной БД, заключающееся в отсутствии в любом её отношении внешних ключей, ссылающихся на несуществующие кортежи.
